In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.preprocessing import MinMaxScaler, OrdinalEncoder
```

In [2]:
```
df = pd.DataFrame({
    "ID":[1,2,3,4,5],
    "Nombre":["Juan","Maria","Pedro","Ana","Luis"],
    "Edad":[32,-28,40,35,50],
    "Salario":[50000,60000,None,55000,200000]
})
```

In [3]:
```
df
```

Out[3]:

	ID	Nombre	Edad	Salario
0	1	Juan	32	50000.0
1	2	Maria	-28	60000.0
2	3	Pedro	40	NaN
3	4	Ana	35	55000.0
4	5	Luis	50	200000.0

In [4]:
```
df.info()
df.isnull().sum()
df.describe()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 4 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   ID       5 non-null      int64
 1   Nombre   5 non-null      object
 2   Edad     5 non-null      int64
 3   Salario  4 non-null      float64
dtypes: float64(1), int64(2), object(1)
memory usage: 292.0+ bytes
```

Out[4]:

	ID	Edad	Salario
count	5.000000	5.00000	4.000000
mean	3.000000	25.80000	91250.000000
std	1.581139	30.84153	72614.851557
min	1.000000	-28.00000	50000.000000
25%	2.000000	32.00000	53750.000000
50%	3.000000	35.00000	57500.000000
75%	4.000000	40.00000	95000.000000
max	5.000000	50.00000	200000.000000

In [5]:
```
print(df.info())
print(df.isnull().sum())
print(df.describe())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 4 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   ID       5 non-null      int64
 1   Nombre   5 non-null      object
 2   Edad     5 non-null      int64
 3   Salario  4 non-null      float64
dtypes: float64(1), int64(2), object(1)
memory usage: 292.0+ bytes
None
ID         0
Nombre     0
Edad       0
Salario    1
dtype: int64
             ID      Edad        Salario
count  5.000000   5.00000       4.000000
mean   3.000000  25.80000   91250.000000
std    1.581139  30.84153   72614.851557
min    1.000000 -28.00000   50000.000000
25%    2.000000  32.00000   53750.000000
50%    3.000000  35.00000   57500.000000
75%    4.000000  40.00000   95000.000000
max    5.000000  50.00000  200000.000000
```

In [6]:
```
df["Edad"] = df["Edad"].abs()
df["Salario"] = df["Salario"].fillna(df["Salario"].median())
df
```

Out[6]:

	ID	Nombre	Edad	Salario
0	1	Juan	32	50000.0
1	2	Maria	28	60000.0
2	3	Pedro	40	57500.0
3	4	Ana	35	55000.0
4	5	Luis	50	200000.0

In [7]:

```
Q1 = df["Salario"].quantile(0.25)
Q3 = df["Salario"].quantile(0.75)

IQR = Q3 - Q1

limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

print("Límite inferior:", limite_inferior)
print("Límite superior:", limite_superior)

df[(df["Salario"] < limite_inferior) | (df["Salario"] > limite_superior)]
```

```
Límite inferior: 47500.0
Límite superior: 67500.0
```

Out[7]:

	ID	Nombre	Edad	Salario
4	5	Luis	50	200000.0

In [8]:

```
df = df[(df["Salario"] >= limite_inferior) & (df["Salario"] <= limite_superior)]

df
```

Out[8]:

	ID	Nombre	Edad	Salario
0	1	Juan	32	50000.0
1	2	Maria	28	60000.0
2	3	Pedro	40	57500.0
3	4	Ana	35	55000.0

In [9]:

```
df = df.copy()

from sklearn.preprocessing import MinMaxScaler

scaler = MinMaxScaler()

df["Salario_Normalizado"] = scaler.fit_transform(df[["Salario"]])

df
```

Out[9]:

	ID	Nombre	Edad	Salario	Salario_Normalizado
0	1	Juan	32	50000.0	0.00
1	2	Maria	28	60000.0	1.00
2	3	Pedro	40	57500.0	0.75
3	4	Ana	35	55000.0	0.50

In [10]:

```
df = df.copy()

df["Años_Hasta_Jubilacion"] = 65 - df["Edad"]

df
```

Out[10]:

	ID	Nombre	Edad	Salario	Salario_Normalizado	Años_Hasta_Jubilacion
0	1	Juan	32	50000.0	0.00	33
1	2	Maria	28	60000.0	1.00	37
2	3	Pedro	40	57500.0	0.75	25
3	4	Ana	35	55000.0	0.50	30

In [11]:

```
import matplotlib.pyplot as plt

plt.figure(figsize=(8,4))
plt.bar(df["Nombre"], df["Salario"])
plt.title("Salario por empleado")
plt.xlabel("Nombre")
plt.ylabel("Salario")
plt.show()
```

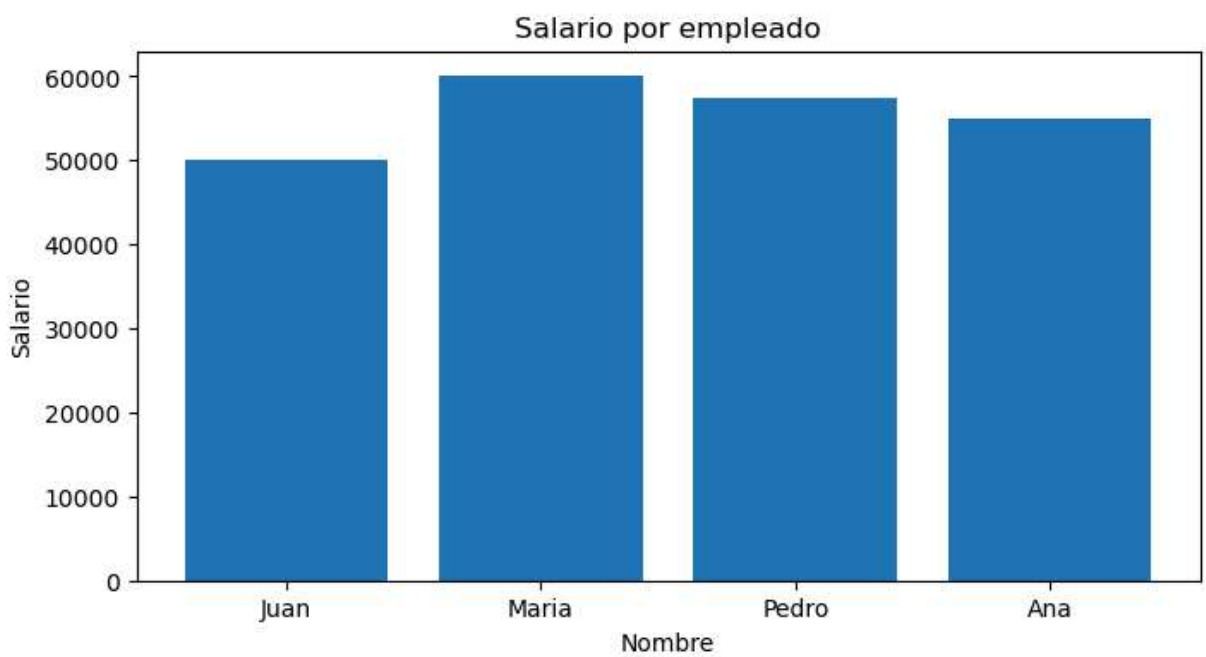

In [12]:
```
plt.figure(figsize=(8,4))
plt.scatter(df["Edad"], df["Salario"])
plt.title("Relación Edad y Salario")
plt.xlabel("Edad")
plt.ylabel("Salario")
plt.show()
```

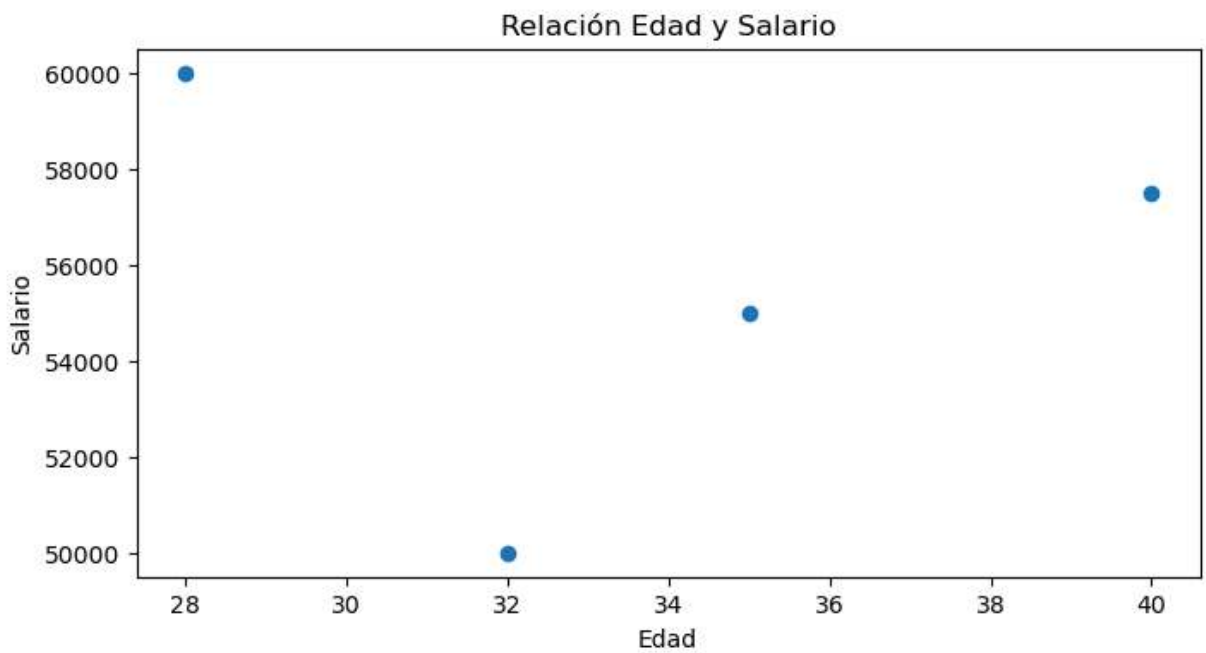

Interpretación de gráficos

El gráfico de barras muestra que María posee el salario más alto dentro del conjunto limpio, mientras Juan tiene el menor salario.

El gráfico de dispersión permite observar la relación entre edad y salario. En este conjunto pequeño no se aprecia una tendencia fuerte, aunque empleados de mayor edad tienden a salarios intermedios o altos.

In [13]:
```
df[["Edad","Salario","Salario_Normalizado","Años_Hasta_Jubilacion"]].corr()
```

Out[13]:

	Edad	Salario	Salario_Normalizado	Años_Hasta_Jubilacion
Edad	1.00000	-0.06753	-0.06753	-1.00000
Salario	-0.06753	1.00000	1.00000	0.06753
Salario_Normalizado	-0.06753	1.00000	1.00000	0.06753
Años_Hasta_Jubilacion	-1.00000	0.06753	0.06753	1.00000

La correlación permite medir la relación entre variables numéricas. Se observa una relación negativa entre Edad y Años_Hasta_Jubilación, ya que mientras aumenta la edad, disminuyen los años restantes para jubilarse.

Uso de LLM

Prompt utilizado:

"Tengo un dataset con salarios y edades. ¿Cómo detectar outliers en Python?"

Síntesis:

El modelo sugirió utilizar el método IQR para identificar valores extremos. Esta recomendación fue aplicada al dataset, detectando el salario de 200000 como valor atípico.

Conclusión

El proceso de limpieza y transformación mejoró la calidad del dataset corrigiendo errores, imputando valores faltantes y eliminando valores extremos. Luego se aplicó normalización y análisis exploratorio para comprender mejor la relación entre variables.

In [ ]:

```
```